

# PROYECTO DE CARGA INCREMENTAL DE DATOS Y AUDITORÍA CON SSIS

ING. SILVA PARRAGUEZ MAXIMO

## I. <u>ENTENDIENDO LA DATA Y EL PROYECTO</u>

### 1. Fuente de datos:

Se usó un dataset que contiene información sobre ventas, beneficios, descuentos, y otros datos relacionados con una tienda minorista ficticia. Incluye datos como fecha de pedido, categoría de producto, región, etc.

Los datos se obtuvieron del repositorio de Kaggle: <a href="https://www.kaggle.com/datasets/vivek468/superstore-dataset-final">https://www.kaggle.com/datasets/vivek468/superstore-dataset-final</a>

La finalidad de este proyecto, empleando SSIS, es lograr que los datos provenientes de una fuente (en este caso, un archivo CSV) se integren en la tabla Ventas\_Destino de SQL Server sin duplicar registros. Se insertarán únicamente los datos nuevos y se actualizarán aquellos registros existentes en caso de modificaciones en la fuente. Además, se implementará una auditoría de cambios que registrará, en la tabla Ventas\_Auditoria, detalles fundamentales como la fecha de actualización, el valor anterior del dato, la columna modificada y, a modo de ejemplo, el usuario junto con su IP o el nombre del equipo que realizó la modificación.

### 2. Columnas:

El datased contiene 21 columnas las cuales se detallan a continuación:

N°	Columna	Descripción
1	Row ID	Identificación única para cada fila.
2	Order ID	Identificación única de pedido para cada Cliente.
3	Order Date	Fecha de pedido del producto.
4	Ship Date	Fecha de envío del producto.
5	Ship Mode	Modo de envío especificado por el Cliente.
6	Customer ID	Identificación única para identificar a cada Cliente.
7	Customer Name	Nombre del Cliente.
8	Segment	El segmento al que pertenece el Cliente.
9	Country	País de residencia del Cliente.
10	City	Ciudad de residencia del Cliente.
11	State	Estado de residencia del Cliente.
12	Postal Code	Código postal de cada Cliente.
13	Region	Región a la que pertenece el Cliente.
14	Product ID	Identificación única del Producto.
15	Category	Categoría del producto solicitado.
16	Sub-Category	Subcategoría del producto solicitado.
17	Product Name	Nombre del Producto
18	Sales	Ventas del Producto.
19	Quantity	Cantidad del Producto.
20	Discount	Descuento otorgado.
21	Profit	Ganancia/Pérdida incurrida.

# II. DESARROLLO DEL PROYECTO

# Paso 1: Preparar la Base de datos y las Tablas:

Se creó tres tablas en una Base de datos:

- Ventas Origen (simula la tabla donde llegan los datos nuevos).
- Ventas\_Destino (almacena los datos consolidados, sin duplicados).
- **Ventas\_Auditoria** (almacena los registros que se modificaron por alguna razón y los detalles de dicha actualización).

```
CREATE DATABASE CARGA INCREMENTAL;
USE CARGA_INCREMENTAL;
-- Tabla de origen (datos nuevos llegan aquí)
CREATE TABLE Ventas_Origen (
   Row_ID INT,
   Order_ID VARCHAR(50),
   Order Date DATE,
   Ship_Date DATE,
   Ship_Mode VARCHAR(50),
   Customer_ID VARCHAR(50),
   Customer_Name VARCHAR(100),
   Segment VARCHAR(50),
   Country VARCHAR(50),
   City VARCHAR(100),
   State VARCHAR(100),
   Postal_Code VARCHAR(50),
   Region VARCHAR(50),
   Product_ID VARCHAR(50),
   Category VARCHAR(50),
   Sub_Category VARCHAR(50),
   Product Name VARCHAR(255),
   Sales DECIMAL(18,2),
   Quantity INT.
   Discount DECIMAL(5,2),
   Profit DECIMAL(18,2)
   Date_Insert DATETIME DEFAULT GETDATE(),
```

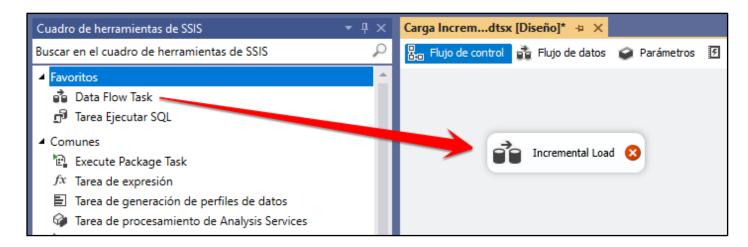
```
- Tabla de destino (solo almacena nuevos o actualizados)
CREATE TABLE Ventas_Destino (
   Row ID INT PRIMARY KEY,
   Order_ID VARCHAR(50),
   Order_Date DATE,
   Ship Date DATE,
   Ship Mode VARCHAR(50),
   Customer_ID VARCHAR(50)
   Customer_Name VARCHAR(255),
   Segment VARCHAR(50),
   Country VARCHAR(50),
   City VARCHAR(255),
    State VARCHAR(255),
   {\tt Postal\_Code\ VARCHAR}(50),\\
   Region VARCHAR(50),
   Product_ID VARCHAR(50),
   Category VARCHAR(50),
   Sub_Category VARCHAR(50),
   Product_Name VARCHAR(255),
   Sales DECIMAL(18,2),
   Quantity INT,
   Discount DECIMAL(5,2),
   Profit DECIMAL(18,2),
   Date_Insert Datetime
```

```
-- Tabla de Auditoría (almacena detalles de modificaciones de algún registros)

CREATE TABLE Ventas_Auditoria (
    ID_Auditoria INT IDENTITY(1,1) PRIMARY KEY,
    Row_ID INT,
    Order_ID VARCHAR(50),
    Fecha_Actualizacion DATETIME DEFAULT GETDATE(),
    Columnas_Modificadas VARCHAR(255),
    Valores_Anteriores NVARCHAR(MAX),
    Usuario NVARCHAR(255) DEFAULT SUSER_NAME(), -- Usuario que hizo la modificación
    IP_Equipo NVARCHAR(50) DEFAULT HOST_NAME() -- IP o nombre del equipo que realizó la modificación
);
```

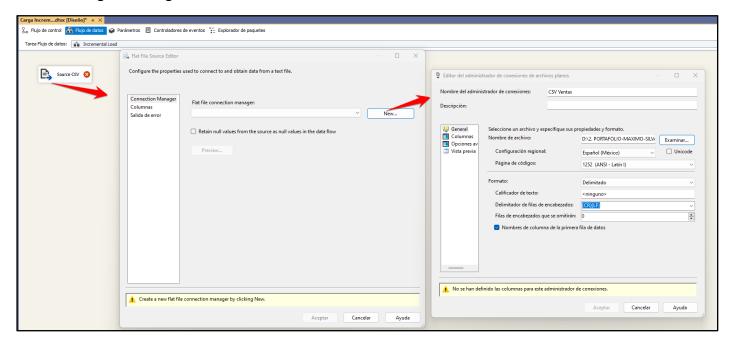
# Paso 2: Creando un proyecto en SSIS.

Creé un nuevo proyecto y utilicé el componente de Data Flow Task.



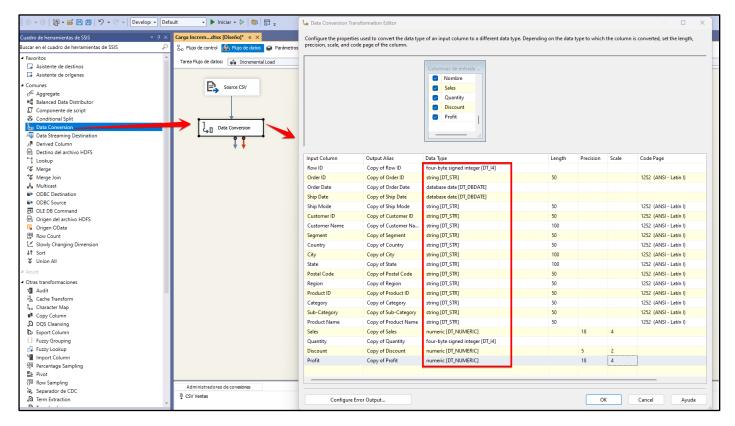
Paso 3: Source CSV.

Configuré el Origen de Datos desde el dataset en formato CSV:



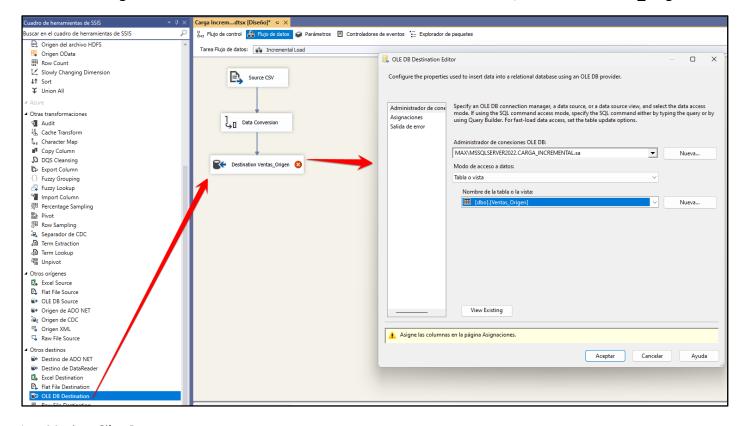
### Paso 4: Componente Data Conversion.

Emplearé el componente de conversión de datos según el tipo de datos en la BD.

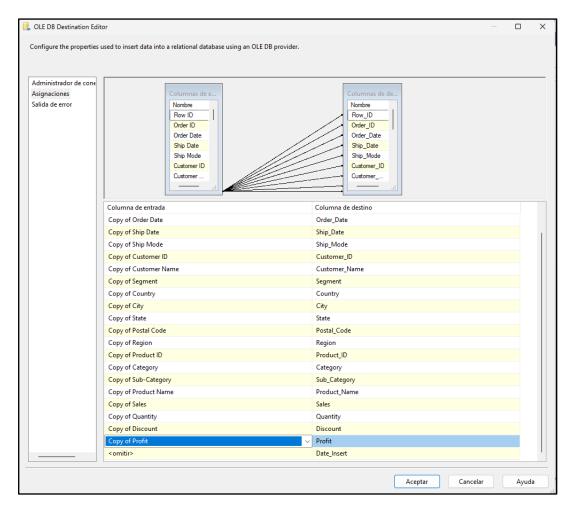


Paso 5: De Data Conversion a Ventas\_Origen.

Se configura el Destino donde se almacenarán los datos Inicialmente, en la tabla Ventas\_Origen.



Ing. Maximo Silva Parraguez



Paso 6: De Ventas\_Origen a Ventas\_Destino y Ventas\_Auditoria.

Utilicé una consulta SQL que consiste en lo siguiente:

- 1. Cree una Tabla Temporal de Auditoría donde se almacenarán temporalmente los registros de auditoría que se usarán para hacer una comparación más adelante.
- Se registran en la Tabla Temporal los registros que han cambiado, es decir, hace una comparación de los Registros de la tabla Ventas\_Destino con los registros de Ventas\_Origen y si encuentra datos que han cambiado, se registra en la tabla temporal de Auditoría.
- 3. Se insertan los registros que se modificaron en la tabla Ventas\_Auditoria desde la tabla Temporal.
- 4. Se actualizan los datos si es que hubiera, en la tabla Ventas Destino.
- 5. Se insertar los datos nuevos si no existen en la tabla Ventas\_Destino.

```
85
86
           -- 1. Declaración de la tabla variable para almacenar los registros de auditoría
        DECLARE @TempAuditoria TABLE (
87
88
                  Row_ID INT,
                                                                                                   -- Identificador de la fila
89
                   Order_ID VARCHAR(50),
                                                                                                  -- Identificador de la orden
90
                  Fecha_Actualizacion DATETIME,
                                                                                                 -- Fecha y hora en que se actualiza el registro
                  Columnas Modificadas VARCHAR(255), -- Columnas que han sido modificadas

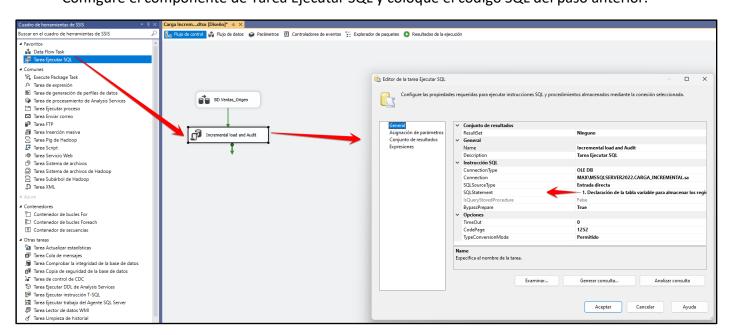
Valores_Anteriores NVARCHAR(MAX) -- Valores anteriores de las columnas modificadas
91
92
93
94
           -- 2. Guardar en la variable de tabla los registros que han cambiado
95
         INSERT INTO @TempAuditoria (Row ID, Order ID, Fecha Actualizacion, Columnas Modificadas, Valores Anteriores)
97
          SELECT
98
                  target.Order_ID,
GETDATE() AS Fecha_Actualizacion,
99
101
                   STRING AGG(CASE
102
                           WHEN target.Order_Date <> source.Order_Date THEN 'Order_Date'
                           WHEN target.Ship_Date <> source.Ship_Date THEN 'Ship_Date
103
                           WHEN target.Ship Mode <> source.Ship Mode THEN 'Ship Mode'
                           WHEN target.Customer_ID <> source.Customer_ID THEN 'Customer_ID'
                           WHEN target.Customer_Name <> source.Customer_Name THEN 'Customer_Name' WHEN target.Segment <> source.Segment THEN 'Segment'
106
107
                           WHEN target.Country <> source.Country THEN 'Country'
WHEN target.City <> source.City THEN 'City'
110
                           WHEN target.State <> source.State THEN 'State'
111
                           WHEN target.Postal_Code <> source.Postal_Code THEN 'Postal_Code'
                           WHEN target.Region <> source.Region THEN 'Region'
                           WHEN target.Product_ID <> source.Product_ID THEN 'Product_ID'
114
                           WHEN target.Category <> source.Category THEN 'Category
                           WHEN target.Sub_Category Source.Sub_Category THEN 'Sub_Category'
WHEN target.Product_Name Source.Product_Name THEN 'Product_Name'
WHEN target.Sales Source.Sales THEN 'Sales'
115
116
118
                            WHEN target.Quantity <> source.Quantity THEN 'Quantity'
119
                           WHEN target.Discount <> source.Discount THEN 'Discount
                  WHEN target.Profit <> source.Profit THEN 'Profit'
END, ', ') AS Columnas_Modificadas, -- Se concatena (separado por comas) los nombres de las columnas que han cambiado.
STRING_AGG(CASE
120
                           WHEN target.Order_Date <> source.Order_Date THEN 'Order_Date: ' + CAST(target.Order_Date AS NVARCHAR)
WHEN target.Ship_Date <> source.Ship_Date THEN 'Ship_Date: ' + CAST(target.Ship_Date AS NVARCHAR)
WHEN target.Ship_Mode <> source.Ship_Mode THEN 'Ship_Mode: ' + target.Ship_Mode
123
124
125
                          WHEN target.Ship_Mode <> source.Ship_Mode THEN 'Ship_Mode: ' + target.Ship_Mode
WHEN target.Customer_ID <> source.Customer_ID THEN 'Customer_ID: ' + target.Customer_ID
WHEN target.Customer_Name <> source.Customer_Name THEN 'Customer_Name: ' + target.Customer_Name
WHEN target.Segment <> source.Segment THEN 'Segment: ' + target.Segment
WHEN target.Country <> source.Country THEN 'Country: ' + target.Country
WHEN target.City <> source.City THEN 'City: ' + target.City
WHEN target.State <> source.State THEN 'State: ' + target.State
WHEN target.Postal Code <> source.State THEN 'State: ' + target.State
WHEN target.Postal Code <> source.Postal Code <> source.State Code <> source.St
126
127
128
129
130
131
```

```
WHEN target.Region <> source.Region THEN 'Region: ' + target.Region
WHEN target.Product_ID <> source.Product_ID THEN 'Product_ID: ' + target.Pro
WHEN target.Category <> source.Category THEN 'Category: ' + target.Category
                                                                                                              + target.Product ID
135
                   WHEN target.Sub_Category <> source.Sub_Category THEN 'Sub_Category: ' + target.Sub_Category WHEN target.Product_Name <> source.Product_Name THEN 'Product_Name: ' + target.Product_Name WHEN target.Sales <> source.Sales THEN 'Sales: ' + CAST(target.Sales AS NVARCHAR)
136
137
                   WHEN target.Quantity <> source.Quantity THEN 'Quantity: ' + CAST(target.Quantity AS NVARCHAR)
WHEN target.Discount <> source.Discount THEN 'Discount: ' + CAST(target.Discount AS NVARCHAR)
WHEN target.Profit <> source.Profit THEN 'Profit: ' + CAST(target.Profit AS NVARCHAR)
139
140
141
              END, '; ') AS Valores_Anteriores -- Se concatena (separado por punto y coma) el nombre de la columna y su valor anterior
142
         FROM Ventas_Destino AS target
143
144
        JOIN Ventas_Origen AS source
145
             ON target.Row_ID = source.Row_ID
146
        WHERE
                    target.Order_Date <> source.Order_Date OR
147
148
                   target.Ship_Date <> source.Ship_Date OR
target.Ship_Mode <> source.Ship_Mode OR
149
150
                    target.Customer_ID <> source.Customer_ID OR
                    target.Customer_Name <> source.Customer_Name OR
                    target.Segment <> source.Segment OR
                   target.Country <> source.Country OR
target.City <> source.City OR
target.State <> source.State OR
153
154
155
156
                    target.Postal_Code <> source.Postal_Code OR
                   target.Region <> source.Region OR
target.Product ID <> source.Product ID OR
157
158
159
                    target.Category <> source.Category OR
                   target.Sub_Category <> source.Sub_Category OR
target.Product_Name <> source.Product_Name OR
160
161
162
                    target.Sales <> source.Sales OR
163
                    target.Quantity <> source.Quantity OR
164
                    target.Discount <> source.Discount OR
165
                    target.Profit <> source.Profit
                   -- Se filtran los registros donde al menos una columna esta diferente entre origen y destino
166
        GROUP BY target.Row_ID, target.Order_ID;
168
         -- 3. Se inserta los cambios en la tabla de auditoría usando la variable de tabla
169
      ☐INSERI INTO Ventas_Auditoria (Row_ID, Order_ID, Fecha_Actualizacion, Columnas_Modificadas, Valores_Anteriores)
☐SELECT * FROM @TempAuditoria; -- Se transfiere los registros auditados a la tabla física Ventas_Auditoria
171
172
             4. Se realiza la actualización en Ventas_Destino usando MERGE
174
       MERGE INTO Ventas_Destino AS target
       USING Ventas_Origen AS source
175
        ON target.Row_ID = source.Row_ID
177
178
       ⊣
--Cuando se encuentra un registro en ambas tablas (MATCHED) v existe al menos una diferencia en alguno de los campos especificados.
         -- se ejecuta la cláusula UPDATE.
180
       WHEN MATCHED AND
181
              target.Order Date <> source.Order Date OR
              target.Ship_Date <> source.Ship_Date OR
```

```
target.Ship_Mode <> source.Ship_Mode OF
          target.Customer_ID <> source.Customer_ID OR
184
185
          target.Customer_Name <> source.Customer_Name OR
186
          target.Segment <> source.Segment OR
187
          target.Country <> source.Country OR
          target.City <> source.City OR
188
          target.State <> source.State OR
189
190
          target.Postal_Code <> source.Postal_Code OR
          target.Region <> source.Region OR
192
          target.Product_ID <> source.Product_ID OR
193
          target.Category <> source.Category OR
194
          target.Sub_Category <> source.Sub_Category OR
          target.Product_Name <> source.Product_Name OR
195
196
          target.Sales <> source.Sales OR
197
          target.Quantity <> source.Quantity OR
198
          target.Discount <> source.Discount OR
          target.Profit <> source.Profit
199
200
201
      THEN
202
      UPDATE SET --Se actualizan los registros
203
          target.Order_Date = source.Order_Date,
          target.Ship_Date = source.Ship_Date,
204
          target.Ship_Mode = source.Ship_Mode,
205
          target.Customer_ID = source.Customer_ID,
207
          target.Customer_Name = source.Customer_Name,
208
          target.Segment = source.Segment,
209
          target.Country = source.Country,
          target.City = source.City,
target.State = source.State,
210
211
          target.Postal Code = source.Postal Code,
212
          target.Region = source.Region,
213
          target.Product_ID = source.Product_ID,
215
          target.Category = source.Category,
216
          target.Sub_Category = source.Sub_Category,
217
          target.Product_Name = source.Product_Name,
218
          target.Sales = source.Sales,
          target.Quantity = source.Quantity,
219
220
          target.Discount = source.Discount,
          target.Profit = source.Profit
223
      -- 5. Se inserta los datos nuevos si no existen en la tabla destino
224
225
      WHEN NOT MATCHED THEN
226
      INSERT (Row_ID, Order_ID, Order_Date, Ship_Date, Ship_Mode, Customer_ID, Customer_Name,
              Segment, Country, City, State, Postal_Code, Region, Product_ID, Category, Sub_Category, Product_Name, Sales, Quantity, Discount, Profit, Date_Insert)
227
228
229
      VALUES (source.Row_ID, source.Order_ID, source.Order_Date, source.Ship_Date, source.Ship_Mode, source.Customer_ID, source.Customer_Name,
230
               source.Segment, source.Country, source.City, source.State, source.Postal_Code, source.Region, source.Product_ID,
231
               source.Category, source.Sub_Category, source.Product_Name, source.Sales, source.Quantity, source.Discount, source.Profit, source.Date_Insert);
```

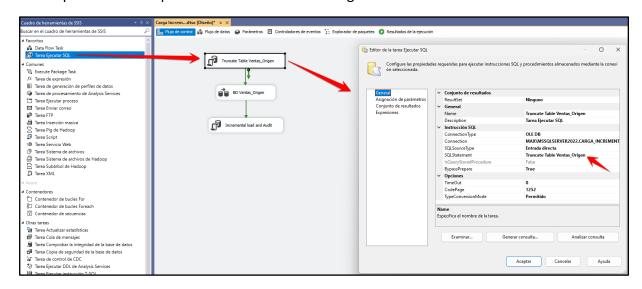
# Paso 7: Componente Tarea Ejecutar SQL.

Configuré el componente de Tarea Ejecutar SQL y coloqué el código SQL del paso anterior.



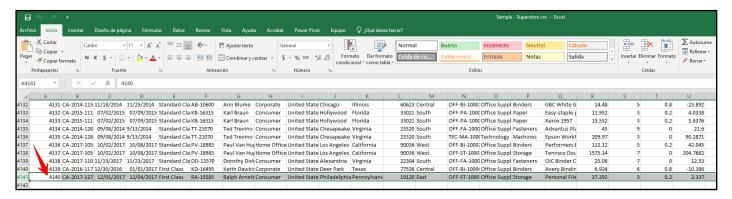
# Paso 8: Limpiando Tabla Ventas\_Origen.

Utilizando un componente de Tarea Ejecutar SQL limpiaré la tabla de Ventas\_Origen, ya que es una tabla que solo se usa para hacer la consulta de carga incremental.

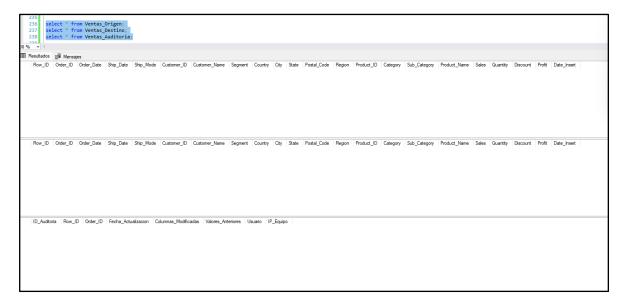


Paso 9: Ejecutando el proyecto y haciendo la verificación de los datos.

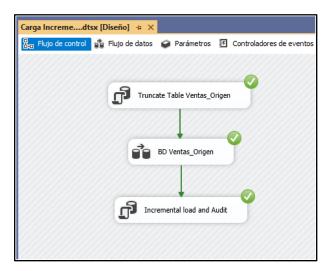
Primero extraje 4140 registros del dataset, y ese lo pasaremos al proyecto de SSIS.



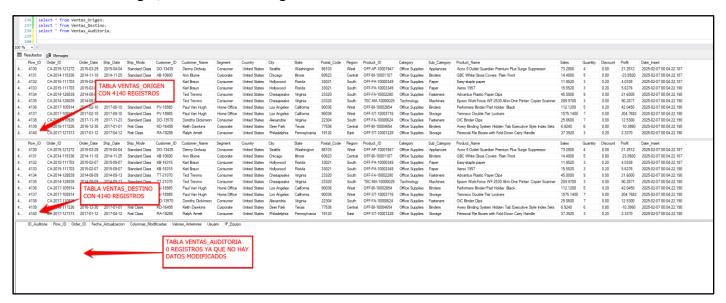
En segundo lugar, verificamos que en las tablas en SQL no existen registros:



En tercer lugar, ejecuto el proyecto.

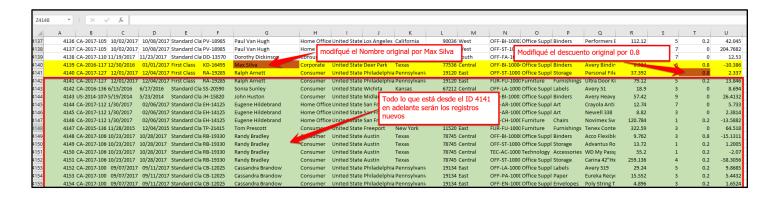


En cuarto lugar, verificamos los registros en las tablas en SQL Server.

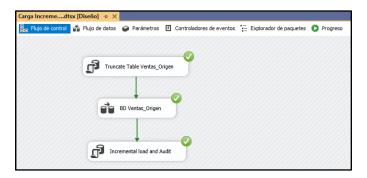


En quinto lugar, al dataset le agregare nuevos datos, **agregaré 60 registros** para que se completen los 4200 registros, y también modificaré los registros con Row ID:

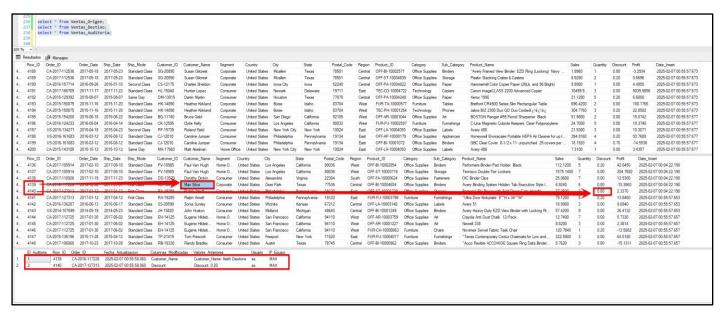
- 4139: Columna Customer Name, cambiaré "Keith Dawkins" por "Max Silva".
- 4140: Columna Discount, cambiaré "0.20" por "0.80".



En sexto lugar, ejecutamos el proyecto, donde debe haber tanto en la tabla Ventas\_Origen como en la tabla Ventas\_Destino un total de 4200 registros y en la tabla Ventas\_Auditoria un total de 2 registros ya que hice dos modificaciones, y también se debe ver reflejado esos cambios en la tabla de Ventas Destino.

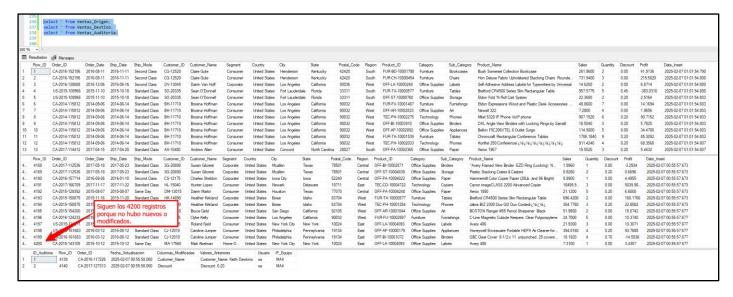


En séptimo lugar, verificamos que efectivamente En la tabla Ventas\_Destino hay un total de 4200 registros donde hay dos modificaciones, las del ID 4139 y 4140, y en la tabla Ventas\_Auditoría, se insertaron los detalles de lo que se modificó.



En Octavo lugar, volveré a ejecutar el mismo proyecto para validar que no se ingresarán mas valores en la tabla Ventas\_Destino, ya que son los mismos que ya se encuentran en ella porque esta vez no haré modificaciones.

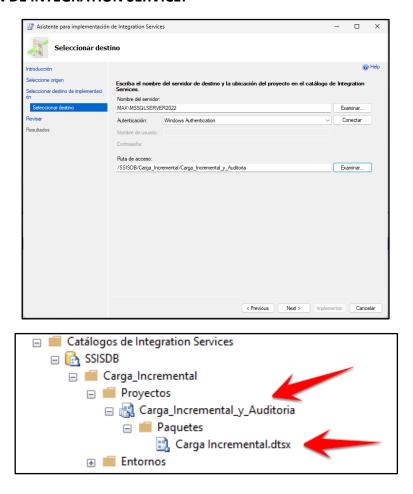




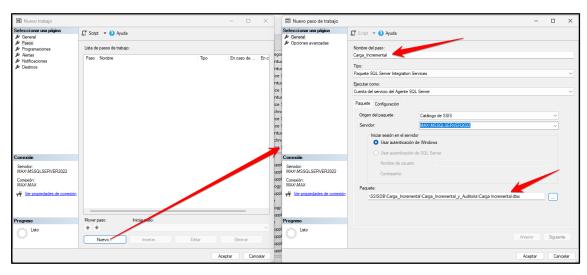
Paso 10: Creando una tarea programada para que se ejecute por ejemplo cada 2 horas.

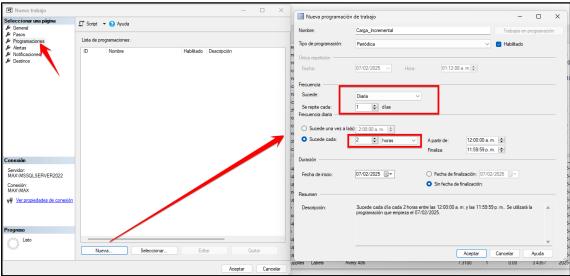
Para este proyecto se configuró una tarea programada para que ejecute el proyecto automáticamente cada 2 horas, para ello primero Implementamos el proyecto de SSIS para que aparezca en el apartado de catálogos en SQL Server, y luego creé una tarea programada.

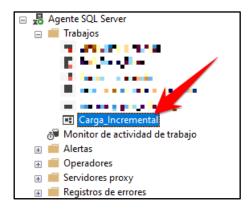
## IMPLEMENTACIÓN DE INTEGRATION SERVICE:



### **CREANDO NUEVO TRABAJO:**







Finalmente, con esto, automáticamente todos los días se hará ese proceso cada 2 horas, teniendo como fuente el archivo CSV que contiene el dataset y destino final Ventas\_Destino, pero se puede realizar con cualquier origen de datos que se este insertando datos cada cierto tiempo y así tener una auditoría de los registros y sus modificaciones como también datos consistentes, sólidos y que no se repiten en Ventas\_ Destino.